



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА У
НОВОМ САДУ



Лазар Нагулов

DSL и LSP за генерисање тест података

ЗАВРШНИ РАД

Основне академске студије

Нови Сад, 2026

	УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА 21000 НОВИ САД, Трг Доситеја Обрадовића 6	Број:
	ЗАДАТАК ЗА ЗАВРШНИ РАД	Датум:

(Податке уноси предметни наставник - ментор)

Студијски програм:	Софтверско инжењерство и информационе технологије		
Студент:	Лазар Нагулов	Број индекса:	SV61/2022
Степен и врста студија:	Основне академске студије		
Област:	Електротехничко и рачунарско инжењерство		
Ментор:	Игор Дејановић		
НА ОСНОВУ ПОДНЕТЕ ПРИЈАВЕ, ПРИЛОЖЕНЕ ДОКУМЕНТАЦИЈЕ И ОДРЕДБИ СТАТУТА ФАКУЛТЕТА ИЗДАЈЕ СЕ ЗАДАТАК ЗА ЗАВРШНИ РАД, СА СЛЕДЕЋИМ ЕЛЕМЕНТИМА: - проблем – тема рада; - начин решавања проблема и начин практичне провере резултата рада, ако је таква провера неопходна;			

НАСЛОВ ЗАВРШНОГ РАДА:

DSL и LSP за генерисање тест података

ТЕКСТ ЗАДАТКА:

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Quia ipsum suspendisse ultram gravida. Risus commodo viverra maecenas accumsan.
--

Руководилац студијског програма:	Ментор рада:

Примерак за: □ - Студента; □ - Ментора
--



УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА
21000 НОВИ САД, Трг Доситеја Обрадовића 6

КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА

Редни број, РБР:	
Идентификациони број, ИБР:	
Тип документације, ТД:	Монографска документација
Тип записа, ТЗ:	Текстуални штампани материјал
Врста рада, ВР:	Дипломски - бечелор рад
Аутор, АУ:	Лазар Нагулов
Ментор, МН:	Др Игор Дејановић, редовни професор
Наслов рада, НР:	DSL и LSP за генерисање тест података
Језик публикације, ЈП:	српски/ћирилица
Језик извода, ЈИ:	српски/енглески
Земља публикавања, ЗП:	Република Србија
Уже географско подручје, УГП:	Војводина
Година, ГО:	2026
Издавач, ИЗ:	Ауторски репринт
Место и адреса, МА:	Нови Сад, трг Доситеја Обрадовића 6
Физички опис рада, ФО: (поглавља/страна/ цитата/табела/слика/графика/прилога)	8/45/23/0/19/0/2
Научна област, НО:	Електротехничко и рачунарско инжењерство
Научна дисциплина, НД:	Примењене рачунарске науке и информатика
Предметна одредница/Кључне речи, ПО:	Шаблон, завршни рад, упутство
УДК	
Чува се, ЧУ:	У библиотеци Факултета техничких наука, Нови Сад
Важна напомена, ВН:	
Извод, ИЗ:	Овај документ представља упутство за писање завршних радова на Факултету техничких наука Универзитета у Новом Саду. У исто време је и шаблон за Typst.
Датум прихватања теме, ДП:	
Датум одбране, ДО:	01.01.2025
Чланови комисије, КО:	Председник: Др Петар Петровић, ванредни професор
	Члан: Др Марко Марковић, доцент
	Члан:
Члан, ментор:	Др Игор Дејановић, редовни професор
	Потпис ментора



UNIVERSITY OF NOVI SAD • FACULTY OF TECHNICAL SCIENCES
21000 NOVI SAD, Trg Dositeja Obradovića 6

KEY WORDS DOCUMENTATION

Accession number, ANO :	
Identification number, INO :	
Document type, DT :	Monographic publication
Type of record, TR :	Textual printed material
Contents code, CC :	
Author, AU :	Lazar Nagulov
Mentor, MN :	Igor Dejanović, Phd., full professor
Title, TI :	DSL and LSP for test data generation
Language of text, LT :	Serbian
Language of abstract, LA :	Serbian/English
Country of publication, CP :	Republic of Serbia
Locality of publication, LP :	Vojvodina
Publication year, PY :	2026
Publisher, PB :	Author's reprint
Publication place, PP :	Novi Sad, Dositeja Obradovica sq. 6
Physical description, PD : (chapters/pages/ref./tables/pictures/graphs/appendixes)	8/45/23/0/19/0/2
Scientific field, SF :	Electrical and Computer Engineering
Scientific discipline, SD :	Applied computer science and informatics
Subject/Key words, S/KW :	Template, thesis, tutorial
UC	
Holding data, HD :	The Library of Faculty of Technical Sciences, Novi Sad
Note, N :	
Abstract, AB :	This document provides guidelines for writing final theses at the Faculty of Technical Sciences, University of Novi Sad. At the same time, it serves as a Typst template.
Accepted by the Scientific Board on, ASB :	
Defended on, DE :	01.01.2025
Defended Board, DB :	President: Petar Petrović, Phd., assoc. professor
	Member: Marko Marković, Phd., asist. professor
	Member:
Member, Mentor:	Igor Dejanović, Phd., full professor
	Mentor's sign



УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА
21000 НОВИ САД, Трг Доситеја Обрадовића 6

ИЗЈАВА О НЕПОСТОЈАЊУ СУКОБА ИНТЕРЕСА

Изјављујем да нисам у сукобу интереса у односу ментор – кандидат и да нисам члан породице (супружник или ванбрачни партнер, родитељ или усвојитељ, дете или усвојеник), повезано лице (крвни сродник ментора/кандидата у правој линији, односно у побочној линији закључно са другим степеном сродства, као ни физичко лице које се према другим основама и околностима може оправдано сматрати интересно повезаним са ментором или кандидатом), односно да нисам зависан/на од ментора/кандидата, да не постоје околности које би могле да утичу на моју непристрасност, нити да стичем било какве користи или погодности за себе или друго лице било позитивним или негативним исходом, као и да немам приватни интерес који утиче, може да утиче или изгледа као да утиче на однос ментор-кандидат.

У Новом Саду, дана _____

Ментор

Кандидат

Садржај

1	Увод	1
1.1	Мотивација	1
1.2	Предмет и цињ рада	1
1.3	Допринос рада	1
1.4	Структура рада	1
2	Теоријске основе	3
2.1	Језици специфични за домен	3
2.2	Фазе обраде програмског језика	4
2.3	Међурепрезентације	5
2.4	Систем модула	7
2.5	Генерисање података	9
2.6	Протокол језичких сервера	10
3	Анализа постојећих решења	13
3.1	Језици специфични за домен	13
3.2	Системи за дефинисање шема	13
3.3	Системи за генерисање тест података	13
3.4	Приступи имплементацији језичке подршке	13
4	Дизајн решења	15
4.1	Архитектура система	15
4.2	Дизајн језика специфичног за домен	16
4.3	Дизајн семантичке анализе	18
4.4	Дизајн високонивојске међурепрезентације	18
4.5	Дизајн модула	19
4.6	Дизајн генератора података	20
4.7	Дизајн језичког сервера	20
5	Имплементација	23
5.1	Лексичка анализа	23
5.2	Парсирање	23
5.3	Апстрактно синтаксно стабло	25
5.4	Семантичка анализа	25
5.5	Високонивојска међурепрезентација	25
5.6	Систем модула	25
5.7	Језички сервер	25
6	Резултати и дискусија	27
6.1	Тестирање језика	27
6.2	Тестирање резултата модула	27
6.3	Тестирање језичког сервера	27
6.4	Дискусија резултата	27
7	Закључак	29
8	Будући рад	31
8.1	Средњенивојска међурепрезентација	31
	Списак слика	33
	Списак листинга	35
	Списак коришћених скраћеница	37

Списак коришћених појмова	39
Биографија	41
Литература	43
TODOs	45

TODO: Увод

1.1 Мотивација

TODO: Мотивација

1.2 Предмет и цињ рада

TODO: Предмет и цињ рада

1.3 Допринос рада

TODO: Допринос рада

1.4 Структура рада

TODO: Структура рада

Ово поглавље приказује теоријске концепте неопходне за разумевање архитектуре и имплементације система. Први део дефинише језике специфичне за домен (енг. *Domain Specific Language*, DSL) и њихову класификацију (поглавље 2.1). Други део анализира фазе лексичке, синтаксне и семантичке анализе текста (поглавље 2.2). Трећи део дефинише концепте међурепрезентација у компајлерима (поглавље 2.3). Четврти део описује теоријске основе модуларних система (поглавље 2.4), док је пети сегмент посвећен алгоритмима за стохастичко генерисање података (поглавље 2.5). Напошетку, шести део описује архитектуру протокола језичких сервера (енг. *Language Server Protocol*, LSP) и пратећих стандарда (поглавље 2.6).

2.1 Језици специфични за домен

DSL је програмски језик ограничених могућности намењен решавању проблема у конкретној области [1]. Синтакса и семантика DSL-а прилагођене су конкретном домену [1]. Дефиниција обухвата четири елемента:

- Први елемент чини природа рачунарског програмског језика за давање инструкција рачунару [1]. Структура језика омогућава људима разумевање изворног кода уз задржавање извршности на рачунару [1].
- Други елемент представља флуидност изражавања кроз међусобно комбиновање појединачних језичких конструкција [1].
- Трећи елемент је ограничена експресивност у односу на језике опште намене (енг. *General Purpose Language*, GPL) [1]. Ограничена експресивност подразумева подршку само за минималан скуп функционалности неопходних за домен [1]. Језик онемогућава развој целокупног софтверског система већ решава само један сегмент [1].
- Четврти елемент обухвата јасан фокус на уску област примене [1]. Фокус на домен произилази директно из ограничене могућности изражавања језика [1].

Инжењерство програмских језика прави разлику између DSL и GPL [2]. GPL пружају широк спектар могућности за решавање произвољних софтверских проблема [2]. DSL мењају општу употребљивост за висок ниво апстракције и већу продуктивност унутар изабране области [2].

2.1.1 Класификација језика специфичних за домен

Разликују се интерни (енг. *internal*) и екстерни (енг. *external*) доменски језици [1], [2].

1. Интерни доменски језици реализују се унутар постојећег језика домаћина [1]. Синтакса интерних језика дефинисана је и ограничена синтаксним правилима изабраног језика домаћина [2].
2. Екстерни доменски језици поседују независну синтаксу у односу на друге програмске језике [1]. Развој екстерног језика захтева имплементацију засебног лексичког и синтаксног анализатора за анализу изворног текста [2]. Контрола над синтаксом омогућава креирање оптималних текстуалних конструкција за крајњег корисника [2].

2.1.2 Предности и изазови примене

Примена доменских језика доноси предности у процесу развоја софтвера [2]. Висок ниво апстракције омогућава доменским експертима боље разумевање и лакшу валидацију програмског кода [1]. Употреба специјализованих термина смањује број семантичких грешака и убрзава писање спецификација [2]. Развој доменских језика ствара специфичне инжењерске изазове [2]. Креирање екстерног језика подиже комплексност почетне софтверске архитектуре [1]. Доменски језик захтева изградњу и одржавање пратећих алата попут компајлера, језичких сервера и развојних окружења [2].

2.2 Фазе обраде програмског језика

Обрада доменског језика обухвата низ сукцесивних фаза које преводе изворни код у међурепрезентацију спремну за извршавање [3]. Процес се дели на предњи део (енг. *frontend*) и задњи део (енг. *backend*) преводиоца. Предњи део анализира изворни текст и утврђује исправност структуралних и семантичких правила [4]. Задњи део користи припремљене структуре података за покретање логике извршавања или генерисање циљног кода [1]. Имплементирани предњи део обезбеђује заједничку основу за механизам генерације тест података и језички сервер.

2.2.1 Лексичка анализа

Лексичка анализа представља почетну фазу у процесу обраде изворног кода [3]. Лексички анализатор (енг. *lexer*) прихвата низ карактера из текстуалне датотеке и групише карактере у логичке целине [5]. Логичке целине називају се лексеме [3]. Свака лексема се мапира у одговарајући токен који садржи тип и вредност препознатих карактера [5]. Токени представљају кључне речи, идентификаторе, литерале и операторе језика [4]. Лексички анализатор истовремено филтрира сувишне елементе изворног кода попут размака и коментара [5]. Резултат фазе је низ токена спреман за даљу синтаксну проверу.

2.2.2 Синтаксна анализа


Синтаксна анализа утврђује структуралну исправност низа токена на основу дефинисане граматике језика [3]. Синтаксни анализатор (енг. *parser*) организује примљене токене у хијерархијску структуру података [4]. Хијерархијска структура назива се апстрактно синтаксно стабло (енг. *Abstract Syntax Tree*, AST) [5]. AST приказује операторе и операнде унутар сложених језичких конструкција [4]. Грешке откривене у процесу анализе се прослеђују кориснику или развојном окружењу путем језичког сервера.

2.2.2.1 Пратов синтаксни анализатор

Пратов синтаксни анализатор (енг. *Pratt parser*) је алгоритам синтаксне анализе заснован на првенству оператора одозго надоле [5]. Рад алгоритма почива на нумеричкој вредности која се назива снага везивања (енг. *binding power*, BP). BP експлицитно одређује ниво приоритета сваког оператора у језику [5]. Токенски елементи се мапирају у две функције за обраду изворног текста:

- префиксну функцију (енг. *null denotation* или *nud*), која обрађује токене на самом почетку израза и
- инфиксну функцију (енг. *left denotation* или *led*), која обрађује токене који се појављују са десне стране већ делимично изграђеног стабла [5].

Главна петља алгоритма пореди BP тренутног оператора са BP-ом следећег токена у низу [5]. Синтаксни анализатор наставља са груписањем аргумената у подстабло докле год је BP следећег токена већа од тренутне вредности [5]. Предност приступа је једноставност одржавања програмског кода за анализу математичких операција [4]. Визуелни приказ трансформације линеарног низа токена у хијерархијску структуру на основу BP-а приказан је на слици 1.



Слика 1: Трансформација израза $5 + 2 * 3$ у AST на основу BP-а оператора

2.2.3 Семантичка анализа

Семантичка анализа проверава да ли изворни код поштује правила значења и контекста програмског језика [3]. Фаза користи AST за доношење одлука о исправности програма [4]. Основне активности обухватају проверу компатибилности типова података и дефинисаност коришћених идентификатора [3]. Систем мапира откривене променљиве у структуре података које се називају табеле симбола (енг. *symbol table*) [4]. Табела симбола чува информације о опсегу видљивости, типовима и особинама сваког симбола [4]. Успешна семантичка анализа гарантује исправност улазних спецификација пре покретања алгорита за генерацију тест података [2].

2.3 Међурепрезентације

Међурепрезентација (енг. *Intermediate Representation*, IR) представља интерну структуру података коју преводилац користи за моделовање изворног програма између почетних и завршних фаза обраде [3]. Језички системи ретко врше директно превођење изворног кода у машински или извршни облик. Уместо тога, користи се више сукцесивних нивоа апстракције како би се логика синтаксне анализе раздвојила од семантичке провере, независне оптимизације и коначне генерације кода [6]. Зависно од блискости изворном коду или циљној архитектури, IR се категоризује у високонивојски (енг. *High-level Intermediate Representation*, HIR), средњенивојски (енг. *Medium-level Intermediate Representation*, MIR) и нисконивојски (енг. *Low-level Intermediate Representation*, LIR) [6]. Сваки слој је прилагођен специфичним захтевима фазе извршавања. Развој решења ставља фокус на семантичку анализу унутар HIR слоја, док имплементација MIR и LIR структура представља путању будућег проширења система.

2.3.1 Апстрактно синтаксно стабло

AST чини примарни слој који осликава граматичку структуру изворног текста [4]. AST је резултат фазе синтаксне анализе. За разлику од конкретног синтаксног стабла, AST издваја декоративне елементе језика као што су заграде, тачке и белине [5]. Чворови унутар структуре представљају операторе, семантичке конструкте и језичке директиве, док гране воде ка припадајућим операндима. Особине AST-а пружају основу за почетне фазе синтаксне провере и мапирање локација грешака. Директна повезаност са грама-тиком чини AST неефикасним за претраге глобалних веза.

2.3.2 Интернирање стрингова

Током синтаксне анализе изворног кода, преводилац се сусреће са појавом истих текстуалних идентификатора. Чување и сукцесивно поређење стрингова у сваком чвору IR-а уводи меморијски и рачунарски трошак. Превазилажење трошка постиже се техником интернирања стрингова (енг. *string interning*) [7].

Интернирање стрингова оптимизује меморију кроз имплементацију централизованог, непроменљивог базена стрингова (енг. *string pool*). Сваки стринг се уписује у базен само једном, при чему му се додељује

нумерички идентификатор (енг. *symbol* или *ID*). Фазе унутар компајлерске архитектуре уместо комплетних текстуалних података користе додељене нумеричке кључеве. Замена операција поређења текстуалних низова поређењем целих бројева убрзава семантичку анализу и изградњу форми IR [3].


2.3.3 Дизајнерски шаблон посетилац

Дизајнерски шаблони су виšekратно употребљива решења за учестале проблеме у пројектовању софтвера [8]. У архитектури преводаца, изазов представља проширење функционалности система без модификације класа [9]. За решавање проблема проширења функционалности користи се шаблон посетилац (енг. *Visitor*). Посетилац припада категорији образаца понашања [8].

Намена посетилаца је раздвајање алгорита од структуре података над којом се оперише [8]. У језичким процесорима, структура података је представљена чворовима AST-а [9]. Логика за семантичку анализу, оптимизацију или серијализацију локализује се унутар засебних класа, уместо да се уграђује директно у чворове стабла [9].

Посетилац се заснива на механизму двоструког упућивања (енг. *double dispatch*) [8]. Двоструко упућивање зависи истовремено од типа конкретног објекта посетилаца и од типа конкретног елемента структуре [8]. Структура посетилаца (слика 2) обухвата две компоненте:

- апстракцију елемента (енг. *Element*) која дефинише интерфејс са методом *accept(v: Visitor)* за преусмеравање позива конкретних чворова и
- апстракцију посетилаца која дефинише *visit* методе за извршавање алгоритама над конкретним класама елемената [8].



Слика 2: Структура дизајнерског шаблона посетилац [8]


Посетилац се примењује када су испуњени услови да:

- објектна структура садржи елементе различитих класа са специфичним операцијама за сваку конкретну класу,
- постоји потреба за извршавањем несродних операција над елементима без додавања нових метода у класе структуре, те да
- се хијерархија класа објектне структуре ретко мења услед учесталог додавања нових операција над структуром [8].

Граматика развијеног језика је стабилна [9]. Синтаксна правила су фиксирана [9]. Структура чворова AST-а је због тога непроменљива [9]. Фиксирана хијерархија спречава потребу за накнадним модификацијама постојећих посетилаца. Посетилац омогућава додавање компајлерских пролаза кроз засебне компоненте без измене кода стабла. Примена посетилаца дозвољава независну имплементацију трансформације у HIR [7] и серијализацију података [10].

2.3.4 Високонивојска међурепрезентација

HIR представља корак апстракције у коме се текстуална структура програма трансформише у оријентисани граф релација [7]. Слика 3 приказује разлику између AST-а и HIR-а на примеру једне декларације шаблона. Док AST чува текстуалне идентификаторе и прати синтаксичку структуру програма, HIR користи интерниране идентификаторе и експлицитне везе ка симболима, чиме моделује семантичке односе између конструктора. Изградња HIR-а отпочиње након валидације AST-а. Трансформација се заснива на процесу спуштања (енг. *lowering*). Спуштање елиминише преостале синтаксне декорације и своди изразе на каноичке облике [6].



Слика 3: Поређење AST-а и HIR-а на примеру декларације шаблона.

Улога HIR-а је разрешавање референци, типова и међусобних односа између симбола [3]. HIR интегрише локалне симболе тренутног документа са глобалним симболима који су учитани из модула. Текстуални идентификатори су у фази спуштања замењени интернираним нумеричким кључевима. Фокус се тиме преусмерава са начина на који је код написан на семантичко значење и међусобну повезаност објеката. Компактност релационог графа чини HIR погодним за дуготрајно чување, поновно учитавање модуларних целина и генерисање излазних података.


2.4 Систем модула

Развој језичких система захтева декомпозицију спецификација на мање, независне логичке целине. Концепт модуларности почива на дефинисању изолованих компајлационих јединица (енг. *compilation units*) које међусобно комуницирају путем прецизно одређених интерфејса [2]. Подршка за модуле унутар превијача подразумева стриктно раздвајање локалних опсега видљивости (енг. *scope*) од увезених, спољних симбола. Имплементација система модула намеће потребу за трајним чувањем и дељењем међурезултата компајлације на нивоу датотечног система.

2.4.1 Бинарна серијализација и формати без шеме

Подаци се унутар процеса чувају у меморијским структурама. За трајно складиштење ових структура на диску или за њихов пренос кроз мрежу, потребно је претворити податке из меморије у линеарни низ бајтова. Поступак претварања података у линеарни низ бајтова се назива серијализација (енг. *serialization* или *encoding*) [11]. Серијализовани запис HIR-а и пратеће табеле симбола дефинише компајлирани модул. Процес омогућава имплементацију засебне компајлације (енг. *separate compilation*). Преведени модул се

чува као независна датотека коју друге компајлационе јединице могу увести. Могућност увоза елиминира потребу за поновном синтаксном анализом и анализом изворног кода спољних компоненти [2]. Серијализација и увоз модула су приказани на слици 4.



Слика 4: Процес серијализације компајлираног модула и његовог увоза током компајлације.

Приликом избора механизма за перзистентност IR, основна подела обухвата текстуалне и бинарне формате [11]. Текстуални формати омогућавају читљивост и лако отклањање грешака. Међутим, текстуални формати уводе рачунарски трошак (енг. *parsing overhead*). Разлог је потреба за лексичком и синтаксном анализом при сваком учитавању датотеке. Бинарни формати компактно записују структуре података у облик близак изворном меморијском распореду. Компактно записивање смањује заузеће простора на датотечном систему и убрзава учитавање већ компајлираних модула.

Бинарни формати се деле на системе са строго дефинисаном шемом и самоописујуће формате без унапред одређене шеме (енг. *schemaless*). Системи са шемом (нпр. *Protocol Buffers* и *Apache Avro*) захтевају претходно моделовање података [11]. Пре покретања програма неопходно је и извршавање алата за генерисање изворног кода. Фиксна шема пружа максималну компактност јер бинарни запис не садржи називе поља. Са друге стране, крутост структуре уноси инжењерски трошак уколико се IR често мења. Самоописујући формати (нпр. *MessagePack*) чувају метаподатке о типовима заједно са самим вредностима. Складиштење пратећих ознака омогућава еволуцију објектног модела HIR-а у раним фазама развоја. Избор самоописујућег решења спаја флексибилност текстуалних записа са перформансама бинарног кодирања.

Формат *MessagePack* представља бинарну алтернативу JSON запису која задржава његову флексибилност, али значајно смањује просторну комплексност [10]. Ефикасност се постиже коришћењем типа префикса (енг. *type prefix*), где један бајт истовремено дефинише и тип податка и његову дужину. Тип префикса елиминира потребу за знаковима раздвајања. Карактеристике *MessagePack* формата омогућава мапирање релационих графова у компактне структуре бајтова. Учитавање спољних модула своди се на секвенцијално читање меморије.

2.5 Генерисање података

Генерисање тест података на основу декларативних спецификација заснива се на стохастичком моделовању и рачунарској симулацији [12]. Статичка ограничења из доменског језика преводе се у излазне записе применом алгоритама случајног избора. Алгоритми случајног избора симулирају обрасце података у софтверским системима.

2.5.1 Псеудо-случајни генератори

Симулација у рачунарским системима ослања се на псеудо-случајне генераторе бројева (енг. *Pseudo-Random Number Generator*, PRNG) [13]. Рад алгоритма отпочиње прихватањем почетне вредности под називом семе (енг. *seed*). Генератор користи семе за креирање низа бројева кроз сукцесивне математичке трансформације [14]. Математичке трансформације се најчешће заснивају на модуларној аритметици или манипулацији битовима [14]. Резултујући низ је детерминистички условљен почетном вредношћу. Излазни подаци пролазе статистичке тестове независности [13]. Примењени модел симулира својства случајности [13]. Избор PRNG алгоритма утиче на укупне перформансе система. Избор алгоритма одређује брзину извршавања рачунарских симулација и статистички квалитет генерисаних тест примера.

2.5.2 Униформна расподела

Униформна расподела је статистичка расподела у којој сви исходи унутар дефинисаног интервала $[a, b]$ имају једнаку вероватноћу избора [12]. Функција густине расподеле за непрекидни случај дефинисана је као:

$$\mathcal{U}(x) = \frac{1}{b - a}$$

за

$$a \leq x \leq b$$

У контексту система за генерисање података, када корисник дефинише нумерички или текстуални опсег (нпр. распон година или интервал датума) без навођења додатних метаподатака о структури, систем примењује дискретну или непрекидну униформну расподелу [14]. Униформна расподела додељује једнаку вероватноћу свим вредностима унутар дефинисаног опсега.

2.5.3 Тежински избор


Тежински избор (енг. *weighted selection*) је рачунарска имплементација категоријалне расподеле. Сваки потенцијални исход x_i поседује дефинисан фактор тежине w_i који одређује његову важност [12]. Вероватноћа избора појединачног исхода p_i израчунава се нормализацијом његове тежине у односу на суму свих тежина у скупу:

$$p_i = \frac{w_i}{\sum_{j=1}^n w_j}$$

Алгоритамски, тежински избор се реализује конструисањем низа кумулативних сума [14]. Систем генерише случајан број U из униформне расподеле у интервалу $[0, \sum w_j]$, а затим претрагом проналази индекс сегмента коме тај број припада. Временска комплексност алгоритма зависи од одабраног алгоритма претраживања. Секвенцијално претраживање низа уноси линеарну временску сложеност реда $\mathcal{O}(N)$,

где вредност N представља укупан број категорија. Примена бинарне претраге оптимизује алгоритам и редукује комплексност на $O(\log N)$. Тежински избор обезбеђује моделовање система у којима поједини ентитети имају унапред одређену, већу учесталост појављивања.

Теоријски приказ функције густине униформне расподеле и расподеле вероватноћа категоријалне расподеле дат је на слици 5. Са леве стране приказана је константна густина униформне расподеле на интервалу $[a, b]$, док су са десне стране приказане вероватноће избора појединачних категорија, одређене њиховим тежинама.



Слика 5: Теоријски приказ униформне (лево) и категоријалне расподеле (десно).

2.5.4 Репродуктивност

Репродуктивност је особина система за стохастичко генерисање података која гарантује конзистентност излазних резултата при коришћењу идентичне улазне спецификације [12]. Фиксирање почетне вредности омогућава репликацију интерног стања генератора. Поновљивост обезбеђује детерминистичку репродукцију грешака откривених током извршавања тестова. Стабилност излазних структура оптимизује радне процесе унутар система за аутоматизовану интеграцију. Једнообразност података олакшава размену специфичних тест сценарија међу члановима развојног тима.

2.5.5 Референцијални интегритет и графови зависности


Генерисање сетова података који садрже међусобне везе захтева очување референцијалног интегритета [15]. У контексту синтетизације података, референцијални интегритет је структурно ограничење у коме вредност једног атрибута (страног кључа) мора постојати унутар скупа вредности референцираног ентитета [15]. Ограничење референцијалног интегритета онемогућава независно генерисање вредности и уводи релациону међузависност унутар система.

Међусобне условљености се моделују помоћу усмерених графова зависности (енг. *dependency graph*) [3]. Чворови графа представљају ентитете, док усмерене гране означавају постојање референцијалних веза између њих. Проналажење валидног редоследа извршавања генерације захтева примену алгоритма за тополошко сортирање над конструисаним графом [3]. Тополошко сортирање поставља чворове графа у линеаран низ у коме сваки референцирани ентитет претходи зависном ентитету. Употреба тополошког сортирања успоставља редослед којим се сви примарни објекти креирају у меморији пре отпочињања обраде зависних поља.

2.6 Протокол језичких сервера

LSP је стандардни протокол комуникације између развојних окружења и језичких сервера [16]. Стандард раздваја језички неутралан уредник текста од језичког сервера [17]. Језички сервер извршава статичку и семантичку анализу без познавања специфичности развојног окружења [17]. Развојно окружење управља корисничким интерфејсом без познавања дубље семантике програмског језика [17].

Едитор и језички сервер комуницирају путем *JavaScript Object Notation Remote Procedure Call* (JSON-RPC) протокола [16]. Током уређивања, едитор шаље садржај документа и корисничке захтеве, док језички сервер враћа резултате анализе и податке потребне за функционалности едитора [18]. Слика 6 приказује ток комуникације.



Слика 6: Комуникација између едитора и језичког сервера током уређивања документа [16].

2.6.1 Проблем развоја језичке подршке

Развој подршке за развојна окружења захтевао је засебну имплементацију за сваки програмски језик [17]. Приступ доводи до укупног броја имплементација који одговара производу броја језика и броја развојних окружења [19]. Последице децентрализоване архитектуре обухватају високе трошкове развоја и спорију испоруку софтверских алата [18]. Различита развојна окружења често показују неконзистентно понашање приликом анализе истог изворног кода [18]. Комплексност одржавања онемогућава развојним тимовима пружање квалитетне подршке за више уредника текста [17].

2.6.2 Архитектура протокола језичког сервера

Архитектура користи клијент-сервер модел за раздвајање логике уредника текста од семантике језика [16]. Развојно окружење преузима улогу клијента који управља корисничким интерфејсом [17]. Језички сервер ради као независан процес задужен за статичку анализу кода [19]. Комуникација се ослања на стандардизоване поруке унутар JSON-RPC протокола [16]. Протокол дефинише одређен животни циклус сесије кроз захтеве за иницијализацију и гашење сервера [16]. Размена података обухвата асинхронно слање обавештења о изменама унутар отворених датотека [16]. Сервер извршава анализу у позадини и самостално шаље дијагностичке поруке клијенту [16].

2.6.3 Функционалности протокола језичког сервера

Протокол стандардизује функционалности за подршку током кодирања [16]. Основна могућност обухвата аутоматско допуњавање кода на основу тренутног контекста [16]. Систем омогућава прелазак на место дефиниције симбола у изворном коду [16]. Функционалност претраге референци проналази сва појављивања изабраног идентификатора у пројекту [16]. Приказ информација кроз лебдећи прозор пружа увид у типове података и документацију симбола [16]. Генерисање дијагностичких порука приказује синтаксне и семантичке грешке у реалном времену [19]. Подршка за рефакторисање укључује сигурно аутоматизовано преименовање симбола кроз све датотеке [16].

2.6.4 Конкурентност и механизам отказивања задатака

Унутар LSP-а, перформансе и одзивност корисничког интерфејса зависе од асинхроне обраде захтева [16]. Корисник непрекидно мења изворни код брзим уносом карактера, процеси семантичке анализе могу постати застарели пре него што се изврше до краја. Да би се спречило непотребно заузеће процесорских

ресурса, LSP уводи механизам отказивања задатака путем токена за отказивање (енг. *cancellation token*) [16]. Клијент шаље обавештење о отказивању за сваки захтев чији је резултат постао сувишан услед новог стања у *едитору*. Језички сервер периодично проверава статус токена током дуготрајних операција, прекида тренутно извршавање у случају активације и ослобађа ресурсе за наредну итерацију анализе.

Глава 3

Анализа постојећих решења

Пројектовање и имплементација алата за генерисање података заснованих на наменским језицима захтева анализу тренутног технолошког стања и сродних софтверских архитектура. Развој предложеног решења налази се на пресеку три софтверске области: инжењерства програмских језика, система за дефинисање формалних шема података и наменских платформи за стохастичку синтетизацију тест примера. Имплементација развојног окружења захтева анализу приступа у изградњи језичких сервера.

3.1 Језици специфични за домен

TODO: Језици специфични за домен

3.1.1 *textX*

TODO: *textX*

3.1.2 *JetBrains MPS*

TODO: *JetBrains MPS*

3.2 Системи за дефинисање шема

TODO: Системи за дефинисање шема

3.2.1 *JSON Schema*

TODO: *JSON Schema*

3.2.2 *Protocol Buffers*

TODO: *Protocol Buffers*

3.3 Системи за генерисање тест података

TODO: Системи за генерисање тест података

3.3.1 *Faker*

TODO: *Faker*

3.3.2 *Mockaroo*

TODO: *Mockaroo*

3.4 Приступы имплементацији језичке подршке


TODO: Приступы имплементацији језичке подршке

Циљ софтверског решења је развој DSL-а који омогућава генерисање тест података. Систем као улаз прима текст DSL датотеке и захтеве које *едитор* шаље путем LSP протокола. Излаз система чине текстуалне датотеке са изгенерисаним тест подацима и одговори формирану у складу са LSP спецификацијом.

Ово поглавље описује целокупан процес дизајна система. Архитектура система (поглавље 4.1) приказује глобалну структуру софтвера и међусобне везе између главних компоненти. Наредни сегмент, посвећен језику специфичном за домен (поглавље 4.2), дефинише конкретну синтаксу, граматичка правила и припадајуће структуралне елементе. Семантичка анализа (поглавље 4.3) обухвата начин имплементације правила контекстуалне исправности и процес валидације изворног кода. За премошћавање јаза између текстуалног записа и саме генерације тест података задужена је високонивојска међурепрезентација (поглавље 4.4), која уводи специфичан апстрактни модел. Рашчлањивање унутрашње структуре софтвера на независне компоненте уз дефинисање њихових интерфејса изложено је у оквиру дизајна модула (поглавље 4.5). Напослетку, део о језичком серверу (поглавље 4.7) описује архитектуру подсистема за прихватање LSP захтева, управљање стањем отворених докумената и формирање стандардизованих одговора за развојно окружење. **TODO: Поменути поглавље о генерисању тест података**


4.1 Архитектура система

Архитектура система пројектована је по принципу дељеног језгра. Логика лексичке, синтаксне и семантичке анализе користи у различитим модулима извршавања. Глобална структура софтвера и међусобне везе између главних компоненти приказане су на слици 7.



Слика 7: Дијаграм архитектуре система

Процес преводјења изворне спецификације у финални извештај одвија се кроз неколико узастопних фаза. Ток података и постепена трансформација модела кроз ланац обраде (енг. *pipeline*) у компајлеру илустровани су на слици 8.



Слика 8: Ланац обраде у компајлеру

4.2 Дизајн језика специфичног за домен

Дизајн DSL-а се заснива на декларативном принципу. Корисник описује структуру и ограничења података. Поступак генерисања је потпуно апстрахован. Систем је пројектован као статички типизиран језик. Статичка типизација омогућава рано откривање грешака у спецификацији путем језичког сервера [1], [2].

4.2.1 Директиве и конфигурација контекста

Синтаксне директиве почињу симболом `@`. Директиве служе за глобалну конфигурацију окружења и управљање модулима. Ови конструкти дефинишу метаподатке преводиоца. Пример глобалних директива и увоза модула приказан је на листингу 1.

```

@import "skalarne_definicije.tmod";

@output json { pretty = true; indent = 4; }
@output_path "./izlaz/korisnici.json";

@generate Korisnik[100];

```

Листинг 1: Пример глобалних директива и увоза модула

Директива `@import` омогућава декомпозицију комплексне спецификације на мање модуле. Директива `@output` дефинише излазни формат JSON (енг. *JavaScript Object Notation*) и пратећу индентацију. Директива `@output_path` одређује циљну локацију датотеке на диску. Извршна директива `@generate` покреће генерисање над изабраним шаблоном.

4.2.2 Кориснички типови и синтаксна ограничења

Систем типова подржава проширење примитивних типова кроз увођење корисничких типова са ограничењима. Дефинисање скаларних типова са ограничењима илустровано је на листингу 2.

```

type GodinaStudija = int [range=1..=4];
type ProsecaOcena = float [range=6.0..=10.0];
type BrojIndeksa = string_pattern "2026/${#[4]}";

```

Листинг 2: Дефинисање скаларних типова са ограничењима

Синтаксна конструкција `range` ограничава домен дозвољених нумеричких вредности. Генератор примењује кориснички дефинисану униформну дистрибуцију вредности унутар задатог интервала. Спецификација `string_pattern` користи текстуалне макрое за форматирање псеудо-насумичних низова карактера.

4.2.3 Колекцијски типови и вишедимензионалне структуре

Систем типова подржава дефинисање колекција кроз типске листе. Листе омогућавају груписање више елемената истог базног типа. Број генерисаних елемената контролише се синтаксним ограничењем `count`. `Count` дефинише минималан и максималан број чланова колекције. Дефинисање колекцијских типова и уложених структура приказано је на листингу 3.

```

type Grade = int [range=6..10];
type IntList = [int][count=1..5];
type IntMatrix = [IntList][count=1..5];

template Student {
    grades = [Grade][count=1..5];
    tensor = [IntMatrix][count=1..5];
}

```

Листинг 3: Дефинисање колекцијских типова и вишедимензионалних структура

Конструкт листе прихвата примитивне и кориснички дефинисане скаларне типове. Типски систем дозвољава вишеструко улагање листа. Улагање омогућава креирање сложених вишедимензионалних структура попут матрица и тензора. Генератор стохастички одређује коначну дужину сваке листе унутар дефинисаног интервала приликом инстанцирања шаблона.

4.2.4 Пробабилистичке енумерације

Енумерације дефинишу коначан скуп вредности и припадајуће тежинске факторе дистрибуције. Тежински фактори се експлицитно наводе помоћу оператора `=>`. Пример енумерације са факторима тежине дистрибуције приказан је на листингу 4.

```

enum StatusStudenta {
    Budzet => 7;
    Samofinansiranje => 3;
}

```

Листинг 4: Енумерација са факторима тежине дистрибуције

Генератор користи дефинисане тежине за стохастичко узорковање вредности. Вероватноћа избора ставке буџет износи тачно 70% док за самофинансирање износи 30%. Пробабилистичке енумерације омогућавају подешавање статистичког профила излазних података.

4.2.5 Структурна композиција и наслеђивање

Моделовање сложених објеката извршено је кроз концепте структура (енг. *struct*) и шаблона (енг. *template*). Структура дефинише чист логички контејнер за композицију поља. Шаблон представља активну семантичку јединицу над којом се извршава генерација. Наслеђивање поља дефинише се оператором `:`. Структурна композиција и механизам наслеђивања приказани су на листингу 5.

```

struct Lokacija {
    grad = string;
    drzava = string;
}

template Osoba {
    ime = string;
    adresa = Lokacija;
}

template Zaposleni : Osoba {
    plata = int [range=50000..150000];
}

```

Листинг 5: Структурна композиција и механизам наслеђивања

Шаблон *Zaposleni* аутоматски наслеђује сва поља родитељског шаблона *Osoba*. Наслеђивање обухвата и уложено поље *adresa*. Наслеђивање смањује редундантност приликом спецификације сложених домена. Композиција омогућава хијерархијску организацију података унутар резултујућег записа.

4.2.6 Очување релационог интегритета

Очување логичких веза између генерисаних ентитета реализовано је увођењем кључне речи *ref*. Референцирање вредности ради очувања интегритета илустровано је на листингу 6.

```
template Smer {
    sifra = string_pattern "${A[3]}";
}

template Student {
    id      = int;
    smer_kod = ref Smer.sifra;
}
```

Листинг 6: Референцирање вредности ради очувања интегритета

Кључна реч *ref* сигнализира преводиоцу да вредност поља мора бити преузета из скупа већ изгенерисаних вредности циљног шаблона. Очување релационог интегритета симулира спољне кључеве из релационих база података. Спољни кључеви спречавају појаву неконзистентних података у финалном извештају.

4.3 Дизајн семантичке анализе

Семантичка анализа представља средишњи део аналитичког слоја унутар архитектуре система. Синтаксни анализатор прослеђује изграђен AST семантичком слоју. Семантички анализатор обавља три фазе провере. Излаз ове компоненте обухвата попуњену табелу симбола и скуп дијагностичких порука.

Изградња табеле симбола чини почетну фазу семантичке анализе. Компонента за изградњу табеле симбола пролази кроз структуру стабла помоћу дизајнерског шаблона посетилац [8]. Модул региструје све дефинисане шаблоне, структуре, енумерације и корисничке типове. Компонента прати контекст извршавања кроз улазак у опсеге видљивости и излазак из њих. Систем детектује невалидне контексте попут дефинисања поља изван дозвољених структура. Анализатор проналази дуплиране идентификаторе унутар истог опсега.

Провера типова представља другу фазу семантичке анализе. Модул за проверу типова анализира исправност израза и додељених вредности. Компонента утврђује конкретан тип за сваки конструкт у спецификацији. Систем захтева да тежински фактори унутар енумерација буду искључиво целобројне вредности. Компонента такође контролише број генерисаних ентитета у извршним директивама. Наведени број мора одговарати целобројном типу података. Свако одступање од ових правила резултује генерисањем семантичке грешке о неслагању типова.

Провера референци је завршна фаза семантичке анализе. Компонента контролише постојање свих коришћених идентификатора. Компонента потврђује исправност кључне речи *ref* приликом повезивања поља између различитих шаблона, претражује локалну табелу симбола и табеле симбола из увезених модула. Проверач референци детектује непостојеће родитељске шаблоне у процесу наслеђивања. Фаза очувања интегритета спречава позивање непостојећих поља унутар структура.

4.4 Дизајн високонивојске међурепрезентације

Процес превођења из AST-а у HIR изводи компонента *AstLowering* [3]. *AstLowering* компонента уклања синтаксно-декоративне елементе и трансформише структуре у облике погодне за генерацију података и рад језичког сервера.

HIR обухвата интернирање стрингова, адресирање ентитета, спуштање израза и издвајање ограничења. Базен стрингова преводи текстуалне идентификаторе у нумеричке кључеве типа *StringId* [3]. Поређење стрингова се тиме своди на операције над целим бројевима. Униформно адресирање обезбеђује јединствене кључеве на нивоу модула. Ентитети користе *ItemId* за глобалне ставке и *FieldId* за поља шаблона или структура. Увођењем нумеричких идентификатора, целокупан семантички граф програма постаје независан од оригиналног текстуалног записа. Независност омогућава ефикасну претрагу графа и брзу бинарну серијализацију.

Крајњи резултат процеса спуштања је структура *Module* (листинг 7). *Module* служи као централни контејнер који обједињује све релевантне аспекте једне компајлиране датотеке.

```
struct Module {
    metadata: ModuleMetadata,
    string_pool: StringPool,
    imports: Vec<StringId>,
    directives: Vec<Directive>,
    items: Vec<Item>,
    source_map: SourceMap,
}
```

Листинг 7: Концептуални модел HIR модула

Module структура концептуално повезује метаподатке, базен стрингова, увозне зависности, извршне директиве, компајлиране ставке и мапу изворног кода. Модул се посматра као јединствена, самодовољна целина, погодна за пренос између различитих фаза компајлера.

4.5 Дизајн модула

Дизајн модуларног система инспирисан је архитектуром изолованих метаподатака компајлера *rustc* [7]. Архитектура омогућава организацију дефиниција кроз више датотека и симултани рад језичког сервера са више табела симбола. Систем почива на три дизајнерске компоненте:

- међумодуларно референцирање (поглавље 4.5.1),
- перзистентност и серијализација (поглавље 4.5.2) и
- реконструкција стања за језички сервер (поглавље 4.5.3).

4.5.1 Међумодуларно референцирање

Повезивање симбола између различитих модула захтева модел који разликује локалне ставке од оних које су увезене из спољних датотека. За ову намену дизајнирана је енумерација *ItemRef* (листинг 8).

```
enum ItemRef {
    Local(ItemId),
    Imported { module: StringId, item: ItemId },
}
```

Листинг 8: Енумерација за представљање локалних и увезених референци

Варијанта *Local* користи се када се референцирани ентитет налази унутар истог модула. Варијанта *Imported* омогућава унакрсно референцирање тако што експлицитно чува идентификатор спољног модула и идентификатор саме ставке. Процес разрешавања назива претражује локалне идентификаторе пре него што претрагу преусмери на мапу увезених зависности.

4.5.2 Перзистентност стања

Да би се избегло поновна синтаксна и семантичка анализа зависних датотека, дизајн предвиђа чување анализираног HIR модела на диску. Као формат серијализације изабран је *MessagePack* [10]. *MessagePack* формат обезбеђује компактан бинарни запис и брзу десеријализацију [10]. Централна структура *Module* пројектована је тако да буде потпуно самодовољна приликом уписа и читавања са диска.

Употреба строго типизираних бинарних формата са датотекама шеме уводи развојни трошак при честим изменама HIR модела [11]. Свака промена унутар преводиоца захтевала би ажурирање екстерне шеме. *MessagePack* формат подржава серијализацију самоописујућих бинарних структура без унапред дефинисане шеме. Тиме је очувана комплетна флексибилност измене HIR модела уз задржавање перформанси читавања.

4.5.3 Реконструкција стања за језички сервер


За потребе рада језичког сервера, дизајн обухвата механизам трансформације статичког NIR модела назад у динамичку табелу симбола. Процес захтева итерацију кроз све компајлиране ставке унутар модула и поновно мапирање њихових својстава. Реконструкција омогућава језичком серверу да креира контекст изолованих датотека и изврши ефикасну валидацију међумодуларних веза [7].

4.6 Дизајн генератора података

TODO: Дизајн генератора података


4.7 Дизајн језичког сервера

Језички сервер обухвата три логичка слоја: комуникациони слој (поглавље 4.7.1), аналитички слој (поглавље 4.7.2) и функционални слој (поглавље 4.7.3). Слика 9 приказује компоненте сваког слоја и ток обраде LSP захтева.



Слика 9: Архитектура LSP система и ток обраде LSP захтева.

LSP se заснива на асинхроној размени порука које су вођене спољним догађајима унутар развојног окружења. Временски редослед размене асинхроних порука и след активности унутар система приликом отварања датотеке приказани су на слици 10.



Слика 10: Секвенцијални дијаграм обраде догађаја при отварању датотеке

4.7.1 Комуникациони слој

Комуникациони слој представља улазну тачку система. Задужен је за размену порука између *едитора* и језичког сервера. Слој прима LSP захтеве, управља стањем отворених докумената и прослеђује поруке осталим компонентама система [16].

Улазну тачку комуникационог слоја представља LSP интерфејс. Компонента прихвата захтеве које *едитор* шаље и преводи их у интерне операције система [16]. Након обраде, компонента формира одговор и враћа га *едитору* [16].

Поред LSP интерфејса, комуникациони слој садржи управљач докумената (енг. *document manager*). Компонента прати измене над отвореним документима и одржава њихово стање за потребе даље обраде. Свака измена садржаја документа покреће поновну анализу и ажурирање дијагностичких порука.

Асинхрона природа JSON-RPC протокола узрокује ризик од појаве трке за ресурсе (енг. *race condition*) [16]. Учестали захтеви за измену документа пристижу брже него што систем завршава семантичку анализу претходног стања. Трка за ресурсе може довести до неконзистентности података унутар компајлера. За решавање проблема дизајниран је механизам за отказивање (енг. *cancellation token*). Механизам за отказивање прекида активну нит позадинске анализе уколико из уредника пристигне нови унос. Ресурси сервера се преусмеравају на обраду последњег стања кода.

4.7.2 Аналитички слој

Аналитички слој врши обраду DSL докумената и припрема податке потребне за LSP функционалности. Слој обухвата синтаксну анализу, семантичку анализу и изградњу интерних модела података. Резултат анализе представља HIR, која садржи семантички модел програма независан од синтаксног записа. Кроз серијализацију табеле симбола, HIR омогућава подршку за независне модуле. Језичком серверу HIR пружа могућност симултаног приступа већем броју међусобно повезаних табела симбола. HIR се користи као заједничка основа за LSP функционалности, генерацију тест података и серијализацију модула.

Обрада започиње синтаксном анализом. Синтаксни анализатор трансформише текст документа у AST [3]. У случају уочавања синтаксних неправилности, синтаксни анализатор примењује механизме опоравка од грешака како би наставио са обрадом остатка документа. Овакав приступ омогућава систему да идентификује и прикаже више независних грешака истовремено, уместо прекида обраде при првој грешци [3].

Над генерисаним AST-ом извршава се семантичка анализа. Компонента проверава типове, валидност референци и конзистентност конструкција дефинисаних DSL правилима. Током анализе, формира се локална табела симбола, која садржи дефиниције и везе између елемената програма [3]. Уочене неправилности се

бележе кроз модел дијагностике. Модел садржи опис грешке, ниво озбиљности и локацију у документу [16].

Након успешно завршене семантичке анализе AST се трансформише у HIR. У HIR-у су разрешене референце, типови и односи између симбола, како из тренутног документа, тако и из претходно серијализованих увозних модула. Ово HIR чини погодним за трајно чување и поновно учитавање модуларних целина.

Развој синтаксног анализатора унутар језичког сервера захтева имплементацију опоравка од грешака (енг. *error recovery*). Пратов алгоритам прекида извршавање при првој синтаксној неправилности [9]. Прекидање рада није прихватљиво за рад у реалном времену где корисник пише непотпун код. Проблем је решен увођењем токена за синхронизацију унутар главне петље синтаксног анализатора. Систем у случају грешке изолује неисправан израз и конструише делимично стабло. Синтаксни анализатор наставља са рашчлањивањем остатка документа.

4.7.3 Функционални слој

Функционални слој имплементира кориснички видљиве операције трансформацијом интерних модела у одговоре дефинисане LSP спецификацијом. Слој обухвата компоненте које омогућавају:

- аутоматско допуњавање кода на основу тренутног контекста и симбола доступних у локалној табели симбола и унутар серијализованих HIR модела увезених модула,
- дијагностику грешака, коришћењем резултата семантичке анализе за формирање порука о неправилностима,
- навигацију кроз код која кориснику обезбеђује прелазак на дефиниције симбола кроз глобални опсег дефинисан учитаним табелама симбола и
- приказ додатних информација (енг. *hover*), пружањем контекстуалних описа интеракције са кодом.

Ово поглавље приказује имплементацију развијеног DSL-а и пратећег језичког сервера. Све компоненте система реализоване су у програмском језику *Rust*. Реализација прати фазе дефинисане у поглављу о дизајну. Лексички анализатор преводи изворни текст у ток токена (поглавље 5.1). Парсер трансформише ток токена у AST (поглавља 5.2 и 5.3). Компонента за семантичку анализу врши валидацију над генерисаним стаблом (поглавље 5.4). Систем преводи AST у HIR (поглавље 5.5).

Сваки модул развијен је као независна целина. Модули користе централизоване механизме за управљање грешкама и дијагностиком. Архитектура подржава размену података са језичким сервером. Исправност сваке компоненте потврђена је кроз јединичне и интеграционе тестове.

5.1 Лексичка анализа

Лексичка анализа представља прву фазу превођења. Циљ је трансформисати изворни текст у низ токена. Имплементација користи итератор *Peekable<CharIndices>*. Итератор омогућава обраду текста уз могућност прегледа наредних карактера без померања позиције показивача [20]. Увид у наредне карактере омогућава препознавање вишекарактерних оператора попут `&&`, `||`, `..` и `..=`. Препознавање се извршава без алокације додатног стања у меморији.

За препознавање кључних речи користи се регистар *KEYWORD_REGISTRY*. Регистар је имплементиран помоћу статичке мапе *once_cell::sync::Lazy* [20]. Мапа обезбеђује константно време претраге приликом идентификације резервисаних речи. Сваки токен чува позицију из изворног кода унутар структуре *Span*. Структура *Span* садржи почетну и крајњу линију и колону. Подаци о позицији омогућавају језичком серверу мапирање дијагностичких порука на оригинални текст.

Структура *LexerError* служи за мапирање лексичких неправилности у дијагностичке поруке. Лексички анализатор не прекида рад при наиласку на невалидан карактер или нетерминирани литерал. Компонента генерише грешку и наставља обраду преосталог дела датотеке. Јединични тестови у датотеци *tests.rs* потврђују исправност рада лексичког анализатора. Тестови покривају примитивне токене, сложене операторе и граничне случајеве попут недовршених стрингова. Лексички анализатор обезбеђује структуриране податке за потребе парсера.

5.2 Парсирање

Парсер трансформише низ токена у AST. Имплементација је подељена на засебне датотеке попут *expression.rs*, *statement.rs* и *token_stream.rs*. Централна структура *Parser* управља целокупним процесом синтаксне анализе.

5.2.1 Управљање током токена

Компонента *TokenStream* омогућава предиктивну анализу и вирење унапред (енг. *lookahead*) (листинг 9). Парсер прегледа наредне токене без њиховог уклањања из примарног тока. Преглед токена унапред неопходан је за разликовање литерала и типова података.

```
pub struct TokenStream<I>
where
    I: Iterator<Item = Result<Token, LexerError>>,
{
    lexer: Peekable<I>,
    buffer: VecDeque<Token>,
    last_span: Span,
}
```

Листинг 9: Структура *TokenStream* компоненте

TokenStream користи итератор *Peekable* и интерни бафер *VecDeque* за привремено складиштење токена. Архитектура омогућава управљање стањем тока и прескакање токена током синхронизације. Поље *last_span* служи за праћење последње познате позиције у изворном коду.

5.2.2 Парсирање израза

Обрада израза ослања се на Пратов (енг. *Pratt*) парсер. Функција *parse_expression* прихвата аргумент *precedence* за одређивање приоритета оператора. Логика парсирања подељена је на две фазе. Прва фаза користи позив функције *parse_primary_expression* за обраду атомских вредности попут литерала, идентификатора и заграда. Друга фаза обухвата итеративну проверу наредног токена и поређење са тренутним нивоом приоритета. Парсер позива функцију *parse_infix_expression* за операције над већ обрађеним изразима.

5.2.3 Парсирање исказа

Функција *parse_statement* усмерава ток извршавања на основу врсте токена. Функција позива метод *parse_directive* за кључне речи *output*, *seed* и *import*. Методи *parse_template* и *parse_struct* обрађују шаблоне и структуре. Методи *parse_enum* и *parse_type_declaration* парсирају еnumerације и декларације типова. Искази представљају заокружене семантичке целине попут дефиниција структура или шаблона. Изрази се парсирају унутар блокова *ExpressionStatement* са обавезном тачком-зарезом на крају.

5.2.4 Парсирање типова података и ограничења

Парсер обрађује типове података кроз систем наменских функција. Функција *parse_type* препознаје примитивне типове, листе и кориснички дефинисане типове. Систем подржава додавање семантичких ограничења на типове података. Ограничења се синтаксички дефинишу унутар угластих заграда. Регистар *CONSTRAINTS* садржи листу свих дозвољених врста ограничења. Подржана ограничења укључују опсег, минималну вредност, максималну вредност и дужину. Регистар користи статичку мапу за валидацију идентификатора ограничења током парсирања. Непозната ограничења изазивају прекид парсирања тренутног израза и генерисање одговарајуће грешке.

5.2.5 Парсирање текстуалних шаблона

Језик подржава валидацију стрингова помоћу специјализованих текстуалних шаблона. Функција *parse_string_pattern* анализира садржај текстуалног литерала карактер по карактер. Парсер користи итератор *Peekable<CharIndices>* за навигацију кроз садржај шаблона. Механизам из литерала издваја константне делове и специјалне услове. Услови дефинишу правила попут понављања малих слова, великих слова или бројева. Број понављања карактера може бити дефинисан динамички. Динамички број понављања захтева инстанцирање секундарног лексичког анализатора и парсера. Секундарни парсер обрађује угњевжене изразе унутар угластих заграда шаблона.

5.2.6 Руковање грешкама и синхронизација

Опоравак од грешака реализован је кроз метод *synchronize*. Парсер наставља рад након појаве грешке *ParserError*. Компонента прескаче токене унутар *TokenStream*-а до следећег поузданог граничника. Као граничници служе тачка-зарез или почетак новог исказа. Синхронизација омогућава пријаву више независних синтаксних грешака током једног покретања.

5.2.7 Тестирање синтаксне анализе

Исправност парсера осигурана је кроз скуп аутоматизованих тестова. Јединични тестови проверавају рад парсера у потпуно изолованом окружењу. Изоловано тестирање потврђује правилну конструкцију AST-а за сваки појединачни исказ. Интеграциони тестови верификују правилну комуникацију између лексичког анализатора и парсера. Аутоматизовани тестови спречавају регресије током даљег развоја синтаксних правила.

5.3 Апстрактно синтаксно стабло

AST је имплементирано као модулarna архитектура унутар датотеке *mod.rs*. Систем је подељен на независне логичке целине за изразе, исказе, атрибуте, варијанте, поља и ограничења. Централни чвор за репрезентацију израза у коду је структура *Expression*. Структура *Expression* обједињује енумерацију *ExpressionKind* и поље *span*. Енумерација *ExpressionKind* дефинише све подржане језичке изразе у систему. Варијанте укључују:

- целобројне литерале,
- децималне литерале,
- текстуалне низове,
- логичке вредности и
- идентификаторе.

Рекурзивни чворови за префиксне и инфиксне операторе омогућени су употребом паметних показивача *Box*. Рад са листама имплементиран је преко структуре *Element* која дозвољава придруживање тежинских израза члановима листа.

Целокупна структура програма и синтаксне наредбе представљене су кроз енумерацију *Statement*. Свака варијанта унутар енумерације *Statement* чува сопствене метаподатке о позицији и структури изворног кода. Искази обухватају:

- дефиниције шаблона,
- корисничких структура,
- блока за генерисање и
- компајлерских директива.

Искази који садрже самосталан израз издвајају се унутар наменске структуре *ExpressionStatement*.

За потребе претраге, валидације и трансформације генерисаног стабла развијен је траит *Visitor*. Интерфејс дефинише методе за посету сваког појединачног типа чвора у AST-у. Функције попут *walk_program*, *walk_statement* и *walk_expression* омогућавају рекурзивно кретање кроз дубину стабла. Помоћне функције аутоматски усмеравају посетиоце на угњежене подчворове израза, варијанти и поља.

5.4 Семантичка анализа

TODO: Семантичка анализа

5.5 Високонивојска међурепрезентација

TODO: Високонивојска међурепрезентација

5.6 Систем модула

TODO: Систем модула

5.7 Језички сервер

TODO: Језички сервер

TODO: Резултати и дискусија

6.1 Тестирање језика

TODO: Тестирање језика

6.2 Тестирање резултата модула

TODO: Тестирање резултата модула

6.3 Тестирање језичког сервера

TODO: Тестирање језичког сервера

6.4 Дискусија резултата

TODO: Дискусија резултата

Глава 7

Закључак

TODO: Закључак

8.1 Средњенивојска међурепрезентација

Списак слика

Слика 1	Трансформација израза $5 + 2 * 3$ у АСТ на основу ВР-а оператора	5
Слика 2	Структура дизајнерског шаблона посетилац [8]	6
Слика 3	Поређење АСТ-а и НИР-а на примеру декларације шаблона.	7
Слика 4	Процес серијализације компајлираног модула и његовог увоза током компајлације.	8
Слика 5	Теоријски приказ униформне (лево) и категоријалне расподеле (десно).	10
Слика 6	Комуникација између <i>едитора</i> и језичког сервера током уређивања документа [16].	11
Слика 7	Дијаграм архитектуре система	15
Слика 8	Ланац обраде у компајлеру	16
Слика 9	Архитектура LSP система и ток обраде LSP захтева.	20
Слика 10	Секвенцијални дијаграм обраде догађаја при отварању датотеке	21

Списак листинга

Листинг 1	Пример глобалних директива и увоза модула	16
Листинг 2	Дефинисање скаларних типова са ограничењима	16
Листинг 3	Дефинисање колекцијских типова и вишедимензионалних структура	17
Листинг 4	Енумерација са факторима тежине дистрибуције	17
Листинг 5	Структурна композиција i механизам наслеђивања	17
Листинг 6	Референцирање вредности ради очувања интегритета	18
Листинг 7	Концептуални модел HIR модула	19
Листинг 8	Енумерација за представљање локалних и увезених референци	19
Листинг 9	Структура <i>TokenStream</i> компоненте	24

Списак коришћених скраћеница

Скраћеница	Опис
AST	Abstract Syntax Tree (апстрактно синтаксно стабло)
BP	Binding Power (снага везивања)
DSL	Domain Specific Language (језик специфичан за домен)
GPL	General Purpose Language (језик опште намене)
IR	Intermediate Representation (међурепрезентација)
HIR	High-level Intermediate Representation (високонивојска међурепрезентација)
MIR	Medium-level Intermediate Representation (средњенивојска међурепрезентација)
LIR	Low-level Intermediate Representation (нисконивојска међурепрезентација)
IDE	Integrated Development Environment (интегрисано развојно окружење)
JSON	JavaScript Object Notation (текстуални формат за размену података)
LSP	Language Server Protocol (протокол језичких сервера)
PRNG	Pseudo-Random Number Generator (псеудослучајни генератор бројева)
XML	Extensible Markup Language (прошириви језик за означавање података)

Списак коришћених појмова

Појам	Објашњење
Серијализација	Процес превођења интерних меморијских структура података у линеарни низ бајтова погодан за трајно чување на диску или пренос кроз мрежу.
Засебна компајлација	Метод превођења програмског кода где се изворне датотеке (модули) компајлирају потпуно независно једне од других, чиме се убрзава развој јер нема потребе за поновним превођењем целог система.
Међурепрезентација	Интерни модел података или структура (попут стабла или графа) коју преводилац користи за представљање изворног кода између фазе синтаксне анализе и фазе генерисања излазног кода.
Табела симбола	Структура података коју преводилац користи за мапирање идентификатора (назива променљивих, функција, типова) са њиховим својствима, опсезима видљивости и локацијама.
Самоописујући формат	Формат записа података (бинарни или текстуални) који не захтева унапред дефинисану шему, већ унутар самог записа чува метаподатке о типовима и структурама поља.
Интернирање стрингова	Техника оптимизације меморије којом се јединствени текстуални низови складиште у централизовану структуру (базен стрингова) и мењају за јединствене нумеричке кључеве, чиме се убрзава операција поређења идентификатора.
Спуштање (енг. <i>lowering</i>)	Процес сукцесивне трансформације међурепрезентације унутар преводилаца којим се сложенији језички конструкти и синтаксни украси постепено своде на једноставније, каноничке форме ближе извршном коду.
Двоструко упућивање (енг. <i>double dispatch</i>)	Механизам у коме се избор методе која ће бити извршена врши у извршном времену на основу типова два објекта: објекта који прима позив и објекта који се прослеђује као аргумент.

Биографија

Овде написати своју кратку биографију.

Литература

- [1] M. Fowler, *Domain-Specific Languages*. Addison-Wesley, 2011.
- [2] M. Voelter, *DSL Engineering: Designing, Implementing and Using Domain-Specific Languages*. dslbook.org, 2013.
- [3] A. V. Aho, M. S. Lam, R. Sethi, and J. D. Ullman, *Compilers: Principles, Techniques, and Tools*, 2nd ed. Pearson, 2007.
- [4] T. Parr, *Language Implementation Patterns: Create Your Own Domain-specific and General Programming Languages*. in Pragmatic Bookshelf Series. Pragmatic Bookshelf, 2010. [Online]. Доступно на <https://books.google.rs/books?id=C7xuPgAACAAJ>
- [5] T. Ball, *Writing An Interpreter In Go*. Wainshain Press, 2016.
- [6] S. S. Muchnick, *Advanced Compiler Design and Implementation*. San Francisco, CA: Morgan Kaufmann, 1997.
- [7] The Rust Project Developers, “Guide to rustc Development.” Accessed: July 7, 2026. [Online]. Доступно на <https://rustc-dev-guide.rust-lang.org/>
- [8] E. Gamma, R. Helm, R. Johnson, and J. Vlissides, *Design Patterns: Elements of Reusable Object-Oriented Software*. in Addison-Wesley Professional Computing Series. Addison-Wesley, 1994.
- [9] R. Nystrom, *Crafting Interpreters*. Genever Benning, 2021. [Online]. Доступно на <https://craftinginterpreters.com/>
- [10] S. Furuhashi, “MessagePack Specification.” Accessed: July 7, 2026. [Online]. Доступно на <https://msgpack.org/>
- [11] M. Kleppmann, *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. O'Reilly Media, 2017.
- [12] A. M. Law, *Simulation Modeling and Analysis*, 5th ed. New York, NY: McGraw-Hill Education, 2014.
- [13] D. E. Knuth, *The Art of Computer Programming, Volume 2: Seminumerical Algorithms*, 3rd ed. Reading, MA: Addison-Wesley, 1997.
- [14] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery, *Numerical Recipes: The Art of Scientific Computing*, 3rd ed. New York, NY: Cambridge University Press, 2007.
- [15] R. Elmasri and S. B. Navathe, *Fundamentals of Database Systems*, 7th ed. Pearson, 2016.
- [16] Microsoft, “Language Server Protocol Specification (Version 3.17).” Accessed: April 29, 2026. [Online]. Доступно на <https://microsoft.github.io/language-server-protocol>
- [17] R. Rodriguez-Echeverria, J. L. C. Izquierdo, M. Wimmer, and J. Cabot, “Towards a Language Server Protocol Infrastructure for Graphical Modeling,” in *Proceedings of the 21st ACM/IEEE International Conference on Model Driven Engineering Languages and Systems (MODELS)*, 2018, pp. 370–380.
- [18] D. Bork and P. Langer, “Language Server Protocol: An Introduction to the Protocol, Its Use, and Adoption for Web Modeling Tools,” *Enterprise Modelling and Information Systems Architectures (EMISAJ)*, vol. 18, p. 9:1–9:31, 2023.

-
- [19] H. Bündler, “Decoupling Language and Editor – The Impact of the Language Server Protocol on Textual Domain-Specific Languages,” in *Proceedings of the 7th International Conference on Model-Driven Engineering and Software Development (MODELSWARD)*, 2019, pp. 129–140.
- [20] Rust Project Developers, “The Rust Standard Library Documentation.” 2026.

1. Увод
2. Мотивација
3. Предмет и циљ рада
4. Допринос рада
5. Структура рада
6. Језици специфични за домен
7. textX
8. JetBrains MPS
9. Системи за дефинисање шема
10. JSON Schema
11. Protocol Buffers
12. Системи за генерисање тест података
13. Faker
14. Mockaroo
15. Приступ и имплементацији језичке подршке
16. Поменути поглавље о генерисању тест података
17. Дизајн генератора података
18. Семантичка анализа
19. Високонивојска међурепрезентација
20. Систем модула
21. Језички сервер
22. Резултати и дискусија
23. Тестирање језика
24. Тестирање резултата модула
25. Тестирање језичког сервера
26. Дискусија резултата
27. Закључак